

**Pró-Reitoria Acadêmica
Curso de Ciência da Computação
Trabalho de Programação Concorrente e Distribuída**

RELATÓRIO DO DESENVOLVIMENTO DO PROJETO FINAL

**Autores: Ana Beatriz Cavalcante Amorim
Aline Oliveira de Pinho
Cristhiane Tamilly de M Carvalho
Mateus Tirulli Rozeti**

Orientador: João Robson Santos Martins

SUMÁRIO

1 INTRODUÇÃO.....	2
2 FUNDAMENTAÇÃO TEÓRICA.....	3
2.1 CONCEITOS - COMPUTAÇÃO DISTRIBUÍDA, ESCALABILIDADE E TOLERÂNCIA A FALHAS.....	3
2.2 VANTAGENS E DESVANTAGENS DA ARQUITETURA.....	4
3 ARQUITETURA DAS SOLUÇÕES.....	4
3.1 DIAGRAMA DE COMUNICAÇÃO.....	4
3.2 FORMATO DOS DADOS.....	4
3.3 JUSTIFICATIVAS PARA ESCOLHA DO ALGORITMO DE BUSCA.....	4
4 IMPLEMENTAÇÃO.....	5
5 REFERÊNCIAS BIBLIOGRÁFICAS.....	6

1 INTRODUÇÃO

O presente relatório técnico descreve a concepção, arquitetura e implementação de um sistema de busca distribuído, desenvolvido como projeto final para a disciplina de Programação Concorrente e Distribuída, do curso de Ciência da Computação da Universidade Católica de Brasília (UCB), pelo professor João Robson.

O objetivo central do projeto é aplicar na prática os conceitos teóricos de sistemas distribuídos, como paralelismo, comunicação em rede e tolerância a falhas. Para isso, foi construído um sistema em Java 17 capaz de realizar buscas por substrings em uma base de dados de artigos científicos do arXiv. A arquitetura da solução é composta por três servidores e um cliente que se comunicam obrigatoriamente via Sockets.

Ao longo deste documento, serão detalhados a fundamentação teórica que embasou o projeto, o design da arquitetura, o formato de dados escolhido para a comunicação e a justificativa para o algoritmo de busca implementado.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 CONCEITOS - COMPUTAÇÃO DISTRIBUÍDA, ESCALABILIDADE E TOLERÂNCIA A FALHAS

A computação distribuída é um modelo arquitetural em que um sistema é composto por múltiplos processos independentes que, ao cooperarem através de uma rede, executam uma tarefa comum. Para o usuário final, esses componentes distribuídos idealmente se apresentam como um único sistema coerente, ocultando a complexidade da comunicação e da distribuição de recursos.

A principal diferença em relação à computação paralela — que se limita a múltiplos núcleos em uma única máquina — reside na autonomia dos nós e na comunicação via rede. A carga de trabalho é, portanto, distribuída entre componentes que podem falhar de forma independente. Em virtude dessa arquitetura, a computação distribuída é essencial para a construção de sistemas escaláveis e com alta disponibilidade, como os encontrados em serviços web, bancos de dados e no processamento massivo de dados com ferramentas como o MapReduce.

Arelado a isso, duas das propriedades mais importantes que emergem do paradigma distribuído são a escalabilidade e a tolerância a falhas, ambas cruciais para a construção de sistemas robustos e eficientes.

A escalabilidade refere-se à capacidade de um sistema de expandir sua capacidade para lidar com o aumento da carga de trabalho. Em sistemas distribuídos, isso geralmente é alcançado de forma horizontal, ou seja, adicionando mais nós (máquinas) à rede. Essa abordagem permite que o desempenho cresça de forma proporcional aos recursos adicionados.

No contexto deste projeto, o princípio da escalabilidade é demonstrado pela divisão da base de dados entre os servidores B e C. Essa arquitetura não apenas permite que a busca seja paralelizada, otimizando o tempo de resposta, mas também estabelece um modelo que poderia ser facilmente expandido. Se o volume de dados aumentasse, novos servidores (D, E, etc.) poderiam ser adicionados para particionar ainda mais a carga, sem a necessidade de modificar a estrutura central do sistema.

A tolerância a falhas é a capacidade de um sistema continuar operando adequadamente, mesmo na ocorrência de falhas em um ou mais de seus componentes. Essa característica é uma consequência direta da independência dos nós em uma arquitetura distribuída.

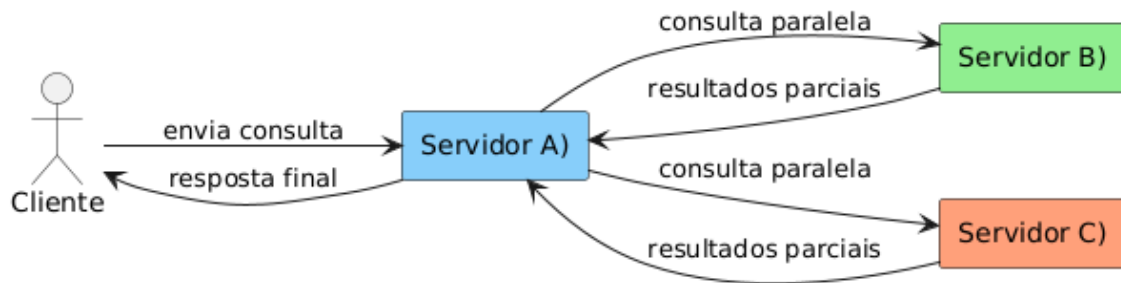
A estrutura deste projeto, embora não implemente mecanismos avançados como replicação de dados ou failover, possui um nível fundamental de tolerância a falhas. Se o Servidor B, por exemplo, se tornar indisponível devido a um erro, o sistema como um todo não cessa sua operação. O Servidor A, atuando como orquestrador, ainda pode obter e consolidar os resultados do Servidor C, retornando uma resposta parcial, porém útil, ao cliente. Isso demonstra a resiliência do modelo distribuído contra falhas parciais.

2.2 VANTAGENS E DESVANTAGENS DA ARQUITETURA

VANTAGENS	DESVANTAGENS
Melhoria na performance via paralelismo.	Maior complexidade de comunicação
Modularidade e facilidade de expansão	Maior custo com gerenciamento de erros
Distribuição da carga de trabalho	Risco de inconsistência sem sincronização

3 ARQUITETURA DAS SOLUÇÕES

3.1 DIAGRAMA DE COMUNICAÇÃO



Obs: O diagrama acima ilustra o fluxo de comunicação entre os componentes durante uma busca.

3.2 FORMATO DOS DADOS

- **Cliente → Servidor A:** string com a palavra-chave ou trecho da busca.
- **Servidor A → Servidores B/C:** mesma string de busca.
- **Servidores B/C → Servidor A:** resposta textual formatada com título e resumo dos artigos.
- **Servidor A → Cliente:** concatenação dos resultados

3.3 JUSTIFICATIVAS PARA ESCOLHA DO ALGORITMO DE BUSCA

A busca nos servidores foi implementada com o algoritmo Knuth-Morris-Pratt (KMP), escolhido por sua alta performance em grandes volumes de texto. Sua eficiência vem de uma fase de pré-processamento sobre o padrão buscado, que permite ao algoritmo saltar de forma inteligente pelo texto após encontrar uma inconsistência, evitando as comparações redundantes dos métodos ingênuos.

Essa técnica resulta em uma complexidade de tempo linear, $O(n + m)$, o que é ideal para o nosso cenário. A varredura rápida dos artigos em cada servidor é fundamental para garantir um baixo tempo de resposta em todo o sistema distribuído.

4 IMPLEMENTAÇÃO

O sistema foi implementado em Java 17 e dividido em três servidores:

- **Servidor A:** atua como orquestrador. Recebe as consultas do cliente e as distribui aos demais servidores;
- **Servidor B:** processa buscas na primeira metade dos dados (arxiv_part1.json);
- **Servidor C:** processa buscas na segunda metade (arxiv_part2.json).

A comunicação entre todos os módulos foi implementada utilizando Sockets TCP para garantir uma troca de dados confiável, atendendo a um requisito obrigatório do projeto. Para otimizar o desempenho, a busca nos servidores B e C é executada em paralelo por meio do framework `ExecutorService`, o que permite ao Servidor A realizar as duas tarefas ao mesmo tempo e reduzir o tempo de resposta para o cliente.

Adicionalmente, foi adotada uma estratégia para acelerar as consultas: os arquivos JSON são carregados na memória uma única vez, durante a inicialização dos servidores. Essa abordagem evita a lenta leitura do disco a cada nova busca, diminuindo drasticamente a latência do sistema.

5 REFERÊNCIAS BIBLIOGRÁFICAS

ARXIV. ARXiv [ONLINE]. DISPONÍVEL EM: [HTTPS://ARXIV.ORG/](https://arxiv.org/). ACESSO EM: 05 JUN. 2025.

CORMEN, T. H.; LEISERSON, C. E.; RIVEST, R. L.; STEIN, C. INTRODUCTION TO ALGORITHMS. 3. ED. CAMBRIDGE: MIT PRESS, 2009.

DEVMEDIA. TRABALHANDO COM JSON EM JAVA: O PACOTE ORG.JSON [ONLINE]. DISPONÍVEL EM: [HTTPS://WWW.DEVMEDIA.COM.BR/TRABALHANDO-COM-JSON-EM-JAVA-O-PACOTE-ORG-JSON/25480](https://www.devmedia.com.br/trabalhando-com-json-em-java-o-pacote-org-json/25480). ACESSO EM: 07 JUN. 2025.

GEEKSFORGEEKS. KMP ALGORITHM FOR PATTERN SEARCHING [ONLINE]. DISPONÍVEL EM: [HTTPS://WWW.GEEKSFORGEEKS.ORG/KMP-ALGORITHM-FOR-PATTERN-SEARCHING/](https://www.geeksforgeeks.org/kmp-algorithm-for-pattern-searching/). ACESSO EM: 15 JUN. 2025.

TANENBAUM, A. S.; VAN STEEN, M. DISTRIBUTED SYSTEMS: PRINCIPLES AND PARADIGMS. 2. ED. UPPER SADDLE RIVER: PEARSON EDUCATION, 2007.